

UNIVERSIDAD AUTONOMA DE CIUDAD JUÁREZ



PROGRAMACIÓN PARA ANALÍTICA DESCRIPTIVA Y PREDICTIVA

TAREA QUE PRESENTA:

OSCAR MORALES MARTINEZ

CD.JUÁREZ, CHIH.

MAYO DEL 2026

Reporte Ejecutivo — Proyecto Final de Machine Learning

Predicción de precios de viviendas utilizando técnicas de Machine Learning

El presente proyecto tuvo como objetivo desarrollar modelos de aprendizaje automático capaces de predecir el precio de venta de viviendas utilizando información estructural y características relacionadas con la propiedad.

Se utilizó el dataset “**House Prices — Advanced Regression Techniques**” de **Kaggle**. La pregunta de negocio planteada fue:

¿Es posible predecir el precio de una vivienda utilizando características estructurales y de ubicación de la propiedad?

El problema fue abordado como una tarea de regresión supervisada.

Metodología

Durante el análisis exploratorio se identificaron variables con valores faltantes, posibles outliers y variables altamente correlacionadas con SalePrice.

Las variables más relevantes incluyeron OverallQual, GrLivArea, GarageCars y TotalBsmtSF.

Para evitar data leakage se utilizaron pipelines con imputación de valores faltantes, escalado y One-Hot Encoding.

Se entrenaron modelos Random Forest Regressor y Gradient Boosting Regressor, utilizando versiones baseline y posteriormente optimizadas mediante GridSearchCV.

Resultados principales

El mejor desempeño fue obtenido por el modelo Gradient Boosting Optimizado.

Métricas finales:

- RMSE: 26681.35
- MAE: 15954.46
- R^2 : 0.9072

Estos resultados indican que el modelo logra explicar aproximadamente el 90.7% de la variabilidad del precio de venta de las viviendas.

El análisis de residuales mostró una distribución relativamente estable alrededor de cero, sugiriendo un ajuste adecuado del modelo.

Conclusiones

Los resultados obtenidos permiten concluir que sí es posible estimar el precio de una vivienda utilizando características estructurales y variables relacionadas con la propiedad.

La optimización de hiperparámetros mejoró el desempeño de los modelos respecto a las versiones baseline.

Entre las principales limitaciones se encuentran la presencia de valores faltantes, posibles outliers y la dependencia del contexto específico del dataset.

Como mejoras futuras podrían implementarse modelos más avanzados como XGBoost o LightGBM, así como técnicas de interpretabilidad y selección de variables.